**Caso 4**

---

Pontificia Universidad Javeriana

Analítica de los negocios

Prof. Juan Nicolás Velasquez Rey

Natalia Valencia Casallas, Juan Pablo Mora Benavides & Daniela Ramírez Castaño

## Parte I: Exploración y descripción de datos

### 1. Descripción del conjunto de datos

Para el análisis se utilizó una muestra de 6,347 clientes de QWE Inc., registrados a diciembre de 2011. Cada observación contiene 12 variables predictoras relacionadas con la antigüedad del cliente, su nivel de satisfacción (CHI Score), el uso de la plataforma y el comportamiento de soporte técnico, además de la variable objetivo Churn que indica si el cliente canceló su contrato en los dos meses siguientes.

### 2. Tabla descriptiva

| Variable | Min | Q1 | Mediana | Media | Q3 | Max | Desv_Est |
|---|---|---|---|---|---|---|---|
| Customer Age (meses) | 0 | 5 | 11 | 13,9 | 20 | 67 | 11,16 |
| CHI Score Mes 0 | 0 | 24,5 | 87 | 87,32 | 139 | 298 | 66,28 |
| CHI Score Cambio 0-1 | -125 | -8 | 0 | 5,06 | 15 | 208 | 30,83 |
| Support Cases Mes 0 | 0 | 0 | 0 | 0,71 | 1 | 32 | 1,72 |
| Support Cases Cambio 0-1 | -29 | 0 | 0 | -0,01 | 0 | 31 | 1,87 |
| SP Mes 0 | 0 | 0 | 0 | 0,81 | 2,67 | 4 | 1,32 |
| SP Cambio 0-1 | -4 | 0 | 0 | 0,03 | 0 | 4 | 1,46 |
| Logins Cambio 0-1 | -293 | -1 | 2 | 15,73 | 23 | 865 | 42,12 |
| Blog Articles Cambio 0-1 | -75 | 0 | 0 | 0,16 | 0 | 217 | 4,66 |
| Views Cambio 0-1 | -28322 | -11 | 0 | 96,31 | 27 | 230414 | 3152,41 |
| Days Since Last Login Cambio 0-1 | -648 | 0 | 0 | 1,76 | 3 | 61 | 17,97 |

Se observa que la antigüedad promedio de los clientes es de 13.9 meses, con valores que van desde 0 hasta 67 meses, lo que sugiere una base de clientes heterogénea en términos de madurez. El CHI Score promedio es de 87.3 puntos, aunque con alta variabilidad (mínimo 0, máximo 298). Las variables de cambio (0-1) presentan valores tanto positivos como

negativos, lo que refleja mejoras y deterioros en el comportamiento de los clientes entre los dos meses analizados.

3. **Gráfico 1: Distribución de la variable Churn en la muestra.**

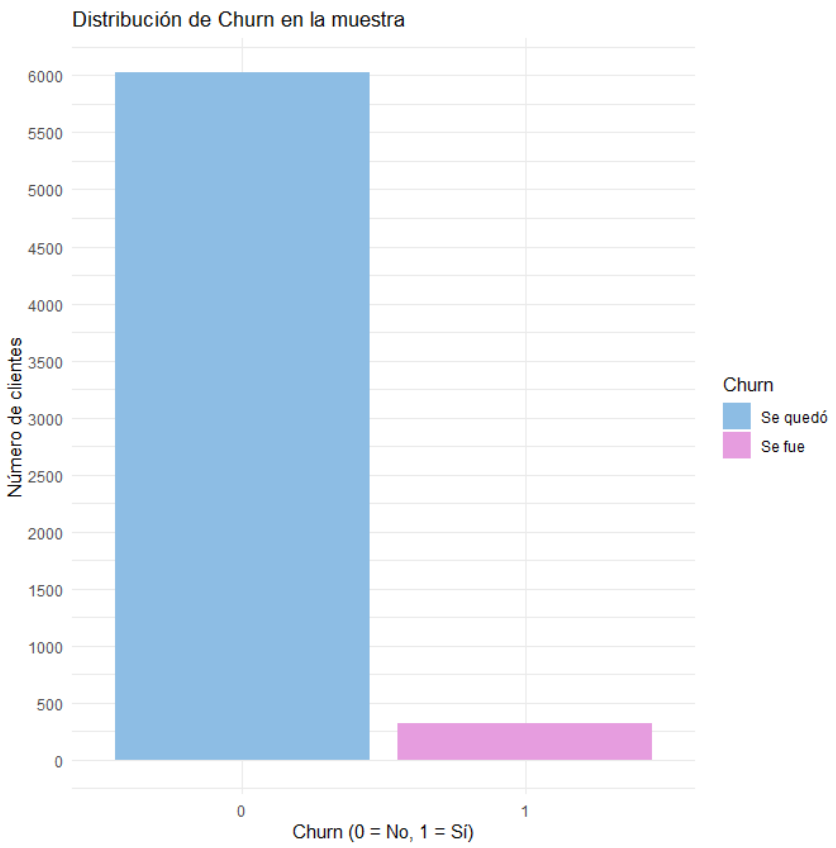


De los 6,347 clientes de la muestra, 6,024 (94.9%) no cancelaron su contrato en el período de análisis, mientras que 323 (5.1%) sí lo hicieron (es decir, realizaron churn). Como se observa en el gráfico 1, existe un marcado desbalance entre las dos clases. Este desbalance es importante porque implica que un modelo que simplemente prediga que ningún cliente se va tendría una precisión aparente del 95%, sin ser realmente útil. Por esta razón, la evaluación del modelo no debe basarse únicamente en la precisión (accuracy), sino también en métricas como la sensibilidad y el área bajo la curva ROC.

**Parte II: Análisis visual - Variables vs. Churn**

**2.1 Gráfico variable I: Antigüedad del cliente vs. Churn**

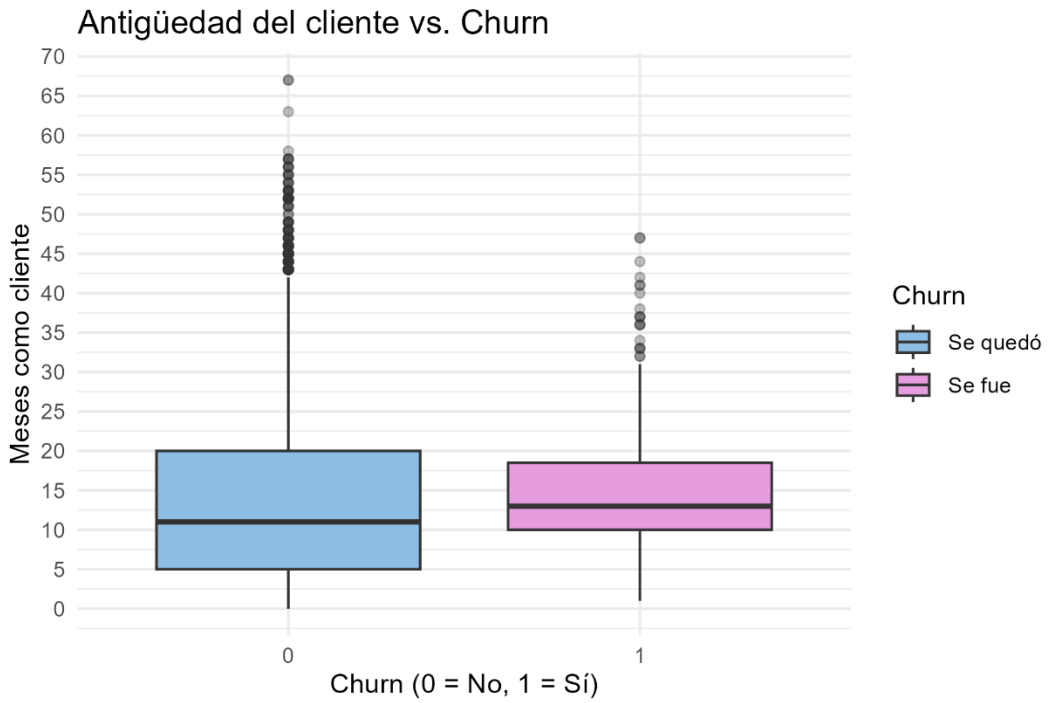


La antigüedad del cliente no muestra una diferencia clara entre grupos. Ambas distribuciones son similares, con medianas cercanas a los 11-13 meses y rangos intercuartílicos que se solapan ampliamente. Esto sugiere que el tiempo que un cliente lleva con QWE no es, por sí solo, un predictor fuerte del churn.

**2.2 Variable 2: CHI Score mes actual**

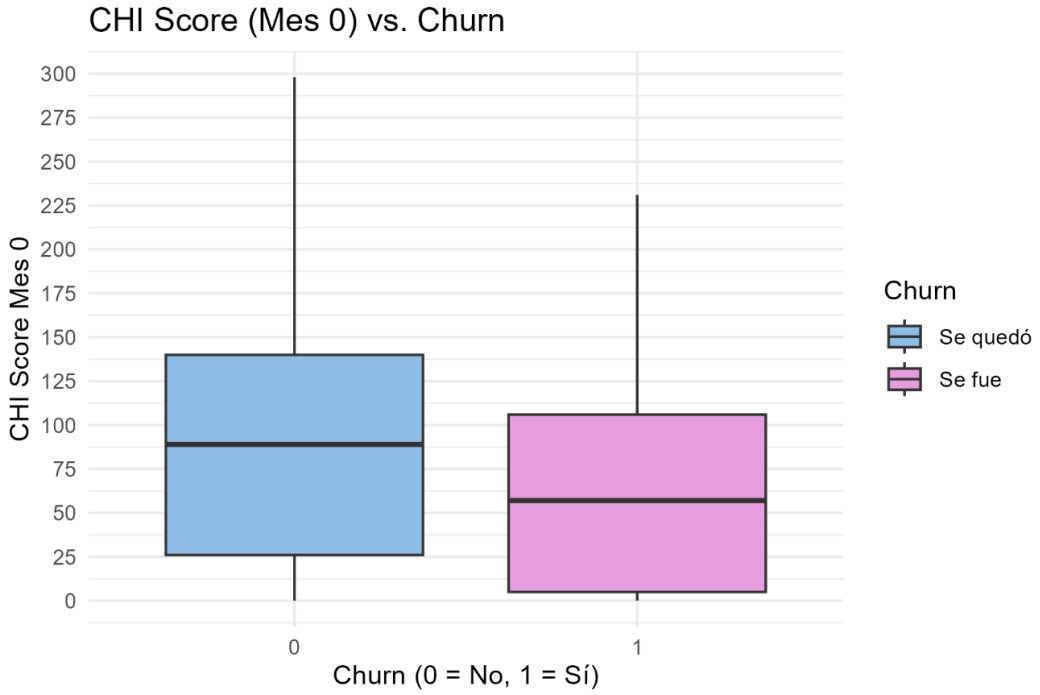

El CHI Score del mes actual muestra una diferencia clara entre grupos. Los clientes que se quedaron (Churn=0) tienen una mediana de aproximadamente 90 puntos, mientras que los que se fueron (Churn=1) tienen una mediana cercana a 60 puntos. Esto sugiere que un menor nivel de satisfacción está asociado con mayor probabilidad de churn, confirmando la intuición de Richard Wall. El CHI Score se perfila como una variable predictora relevante.

**2.3 Variable 3: Cambio en CHI Score**

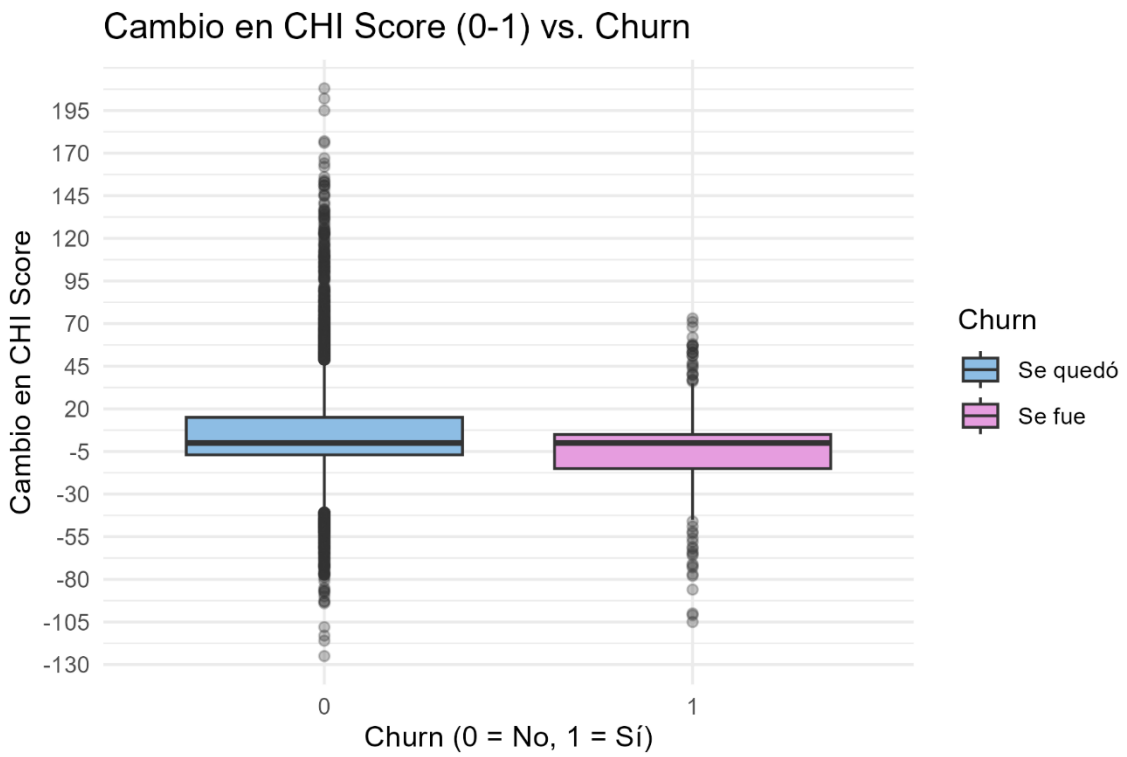


El cambio en el CHI Score entre el mes anterior y el mes actual (0-1) muestra cajas muy similares entre ambos grupos, con medianas cercanas a cero en los dos casos. Sin embargo, los clientes que se quedaron presentan una distribución ligeramente más positiva y con mayor variabilidad. Esto sugiere que el cambio reciente en la satisfacción, por sí solo, no discrimina claramente entre churners y no churners, aunque sí puede aportar información complementaria dentro del modelo.

**2.4 Variable 4: Casos de soporte mes actual**

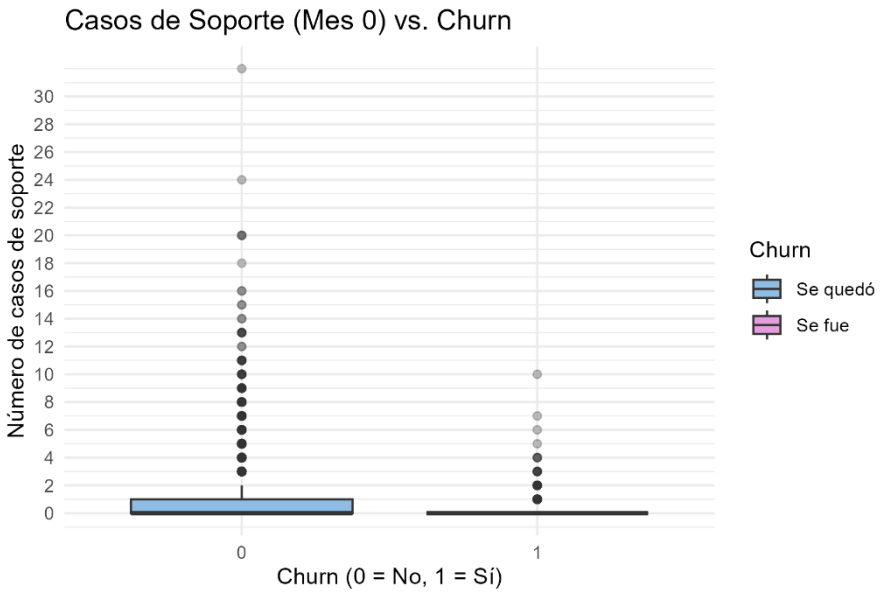


La variable de casos de soporte en el mes actual presenta una distribución muy cargada en valores bajos para ambos grupos, con medianas de 0 en los dos casos. Sin embargo, se observa que los clientes que se quedaron (Churn=0) tienen una caja ligeramente más amplia, lo que indica mayor variabilidad. Los valores atípicos altos aparecen en ambos grupos. Dado que la mayoría de clientes tiene muy pocos casos de soporte, esta variable sola no discrimina bien entre churners y no churners en la exploración visual, aunque podría aportar dentro del modelo logístico en combinación con otras variables

**2.5 Variable 5: Días desde último login**

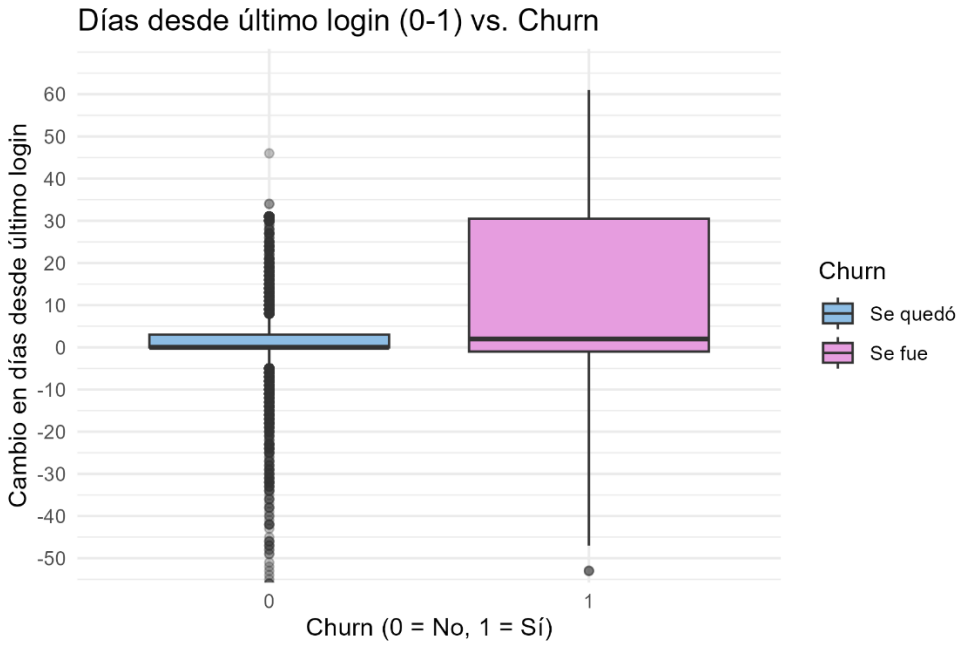

Esta variable muestra una diferencia notable entre grupos. Los clientes que se fueron (Churn=1) tienen una mediana positiva, lo que indica que aumentaron los días transcurridos desde su último login (se conectaron menos frecuentemente antes de cancelar). En contraste, los clientes que se quedaron tienen una mediana cercana a cero. Esto sugiere que la reducción en la frecuencia de uso es una señal de alerta importante para predecir churn.

**Tabla 2. Medias de las variables predictoras según grupo de churn.**

| Churn | Media_Antigüedad | Media_CHI_M0 | Media_CHI_Cambio | Media_Soporte_M0 | Media_Soporte_Cambio | Media_SP_M0 | Media_Logins | Media_Days_Login |
|---|---|---|---|---|---|---|---|---|
| 0 | 13,82 | 88,61 | 5,53 | 0,72 | -0,01 | 0,83 | 16,14 | 1,51 |
| 1 | 15,35 | 63,27 | -3,74 | 0,37 | 0,04 | 0,5 | 8,06 | 6,49 |

La comparación de medias entre grupos revela diferencias importantes. Los clientes que cancelaron su contrato (Churn=1) presentan un CHI Score promedio de 63.27 puntos, notablemente inferior al de los clientes que se quedaron (88.61 puntos), lo que confirma que una menor satisfacción está asociada con mayor probabilidad de abandono. Adicionalmente, el cambio en el CHI Score es negativo para los churners (-3.74) y positivo para los que se quedaron (5.53), indicando que su satisfacción venía cayendo antes de cancelar. En cuanto al uso de la plataforma, los churners registran en promedio 8.06 logins frente a 16.14 de los no churners, y un mayor número de días desde su último login (6.49 vs. 1.51), lo que sugiere una desconexión progresiva del servicio previo a la cancelación. En contraste, la antigüedad promedio y los casos de soporte muestran diferencias menores entre grupos

## Parte III: modelo de regresión logística

### División de los datos

```
indice_train <- createDataPartition(datos_modelo$Churn, p = 0.70, list = FALSE)

# Separar los conjuntos
train <- datos_modelo[indice_train, ]   # 70% para entrenar el modelo
test  <- datos_modelo[-indice_train, ]  # 30% para evaluar el modelo
```

Para generar la división del conjunto, utilizamos la variable creatDataPartition y ponemos como parámetro inicial un 70% para el entrenamiento del modelo. Se hace la partición de esta forma para respetar la distribución de la variable Churn y que los datos generados funcionen en todo el modelo y no solo en los datos de entrenamiento.

### Resultados del $R^2$

| Métrica | Valor |
|---|---|
| Log-Likelihood (modelo completo) | -855,461 |
| Log-Likelihood (modelo nulo) | -896,281 |
| G2 (estadístico) | 81,6388 |
| $R^2$ McFadden | 0,0455 |
| $R^2$ ML | 0,0182 |
| $R^2$ CU (Nagelkerke) | 0,0548 |

Para evaluar el ajuste global del modelo se calculó el pseudo $R^2$ de McFadden, obteniendo un valor de 0.0455. Aunque este valor es bajo en términos absolutos, es importante considerar que en modelos de predicción de churn con datasets muy desbalanceados (5.1% de churners), valores de McFadden entre 0.02 y 0.10 son habituales y no implican necesariamente un mal modelo. La capacidad discriminatoria del modelo debe evaluarse principalmente a través del AUC de la curva ROC, que complementa esta métrica.

**Resultados del modelo —** tabla de coeficientes, significancia estadística y odds ratios

| Variable | Coeficiente | Odds_Ratio | IC_2.5 | IC_97.5 | P_valor | Significancia |
|---|---|---|---|---|---|---|
| (Intercept) | -2,742 | 0,0644 | 0,0499 | 0,0823 | 0 | *** |
| Customer_Age | 0,0133 | 1,0134 | 1,0004 | 1,0258 | 0,0376 | * |
| CHI_Score_M0 | -0,0049 | 0,9951 | 0,9923 | 0,9979 | 0,0007 | *** |
| CHI_Score_01 | -0,0104 | 0,9897 | 0,984 | 0,9955 | 0,0005 | *** |
| Support_Cases_M0 | -0,0904 | 0,9136 | 0,7006 | 1,1135 | 0,4427 | |
| Support_Cases_01 | 0,1367 | 1,1465 | 0,9592 | 1,4556 | 0,1984 | |
| SP_M0 | -0,0562 | 0,9454 | 0,7462 | 1,1989 | 0,6416 | |
| SP_01 | 0,0064 | 1,0064 | 0,8363 | 1,212 | 0,9459 | |
| Logins_01 | 0,0009 | 1,0009 | 0,9959 | 1,0047 | 0,6772 | |
| Blog_Articles_01 | -0,0043 | 0,9958 | 0,9406 | 1,0244 | 0,8623 | |
| Views_01 | -0,0001 | 0,9999 | 0,9998 | 1 | 0,0057 | ** |
| Days_Since_Login_01 | 0,0166 | 1,0167 | 1,0071 | 1,0273 | 0,0011 | ** |

### Interpretación de los coeficientes

Los datos que muestran un efecto estadísticamente significativo sobre el churn son la edad del cliente y los días transcurridos desde el último inicio de sesión, ambos con coeficientes positivos y odds ratios mayores a 1, lo que implica que incrementan el riesgo de abandono y que clientes más viejos y menos activos tiendan a desertar con mayor probabilidad. En comparación, los puntajes de CHI en distintos momentos presentan coeficientes negativos y odds ratios menores a 1, con alta significancia, lo que nos deja ver que un mayor nivel de

satisfacción o engagement medido por este indicador reduce el riesgo de churn y funciona como una medida contra el abandono. Asimismo, el número de vistas también aparece como significativo, con un coeficiente negativo y odds ratio cercano a 1, lo que sugiere que, aunque el efecto es pequeño, una mayor interacción con contenidos disminuye la probabilidad de abandono. Por otro lado, variables como casos de soporte, SP, logins y artículos de blog no muestran efectos estadísticamente significativos, ya que sus intervalos de confianza incluyen valores cercanos a la neutralidad y sus p-valores son altos, lo que impide concluir que tengan un impacto real en el churn. En conclusión, el modelo revela que la edad y la inactividad son factores de riesgo, mientras que el CHI Score y las vistas son factores que aseguran el modelo, y el resto de las variables no aportan evidencia suficiente para explicar el comportamiento de abandono.

**3 factores principales**

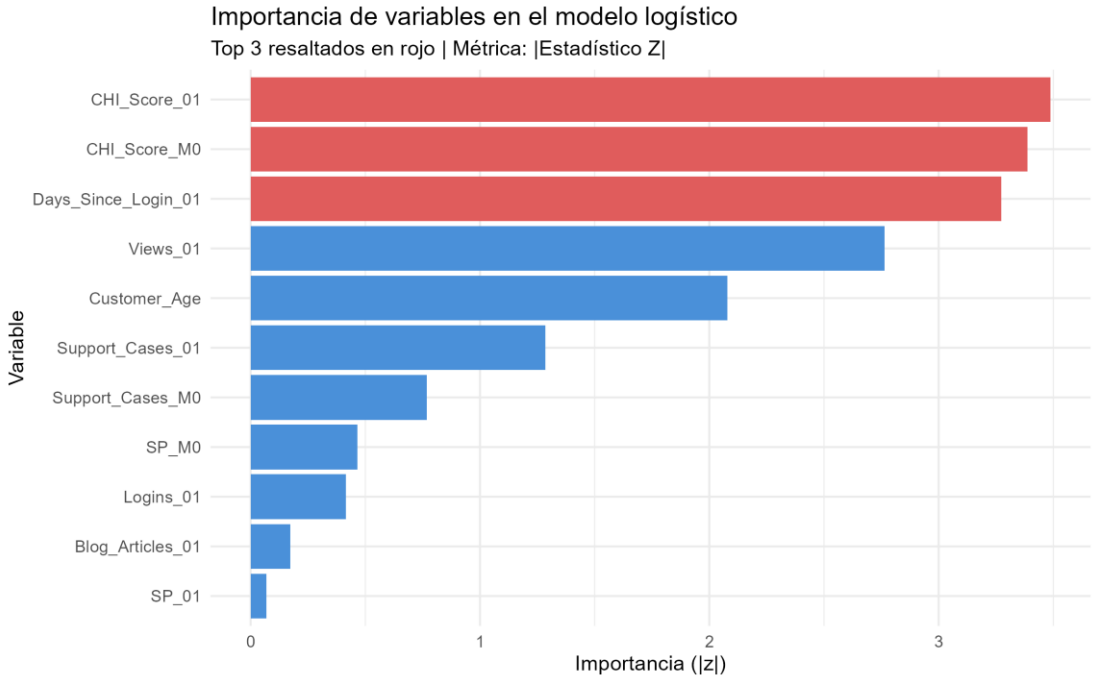


El análisis evidencia que el modelo logístico se apoya principalmente en tres variables críticas: **CHI_Score_01**, **CHI_Score_M0** y **Days_Since_Login_01**, que concentran la mayor capacidad explicativa. Esto confirma que los indicadores de engagement y la actividad desde el inicio del cliente son los factores más determinantes para anticipar comportamientos. En contraste, métricas como casos de soporte, artículos de blog o edad del cliente tienen un impacto marginal. En términos prácticos, la gestión de la experiencia del usuario debe priorizar el fortalecimiento del engagement y la frecuencia de interacción, ya que son los motores clave de la predicción y, por ende, de la estrategia de retención.

**Parte IV: Evaluación y Aplicación del Modelo**

1. **Predicción de probabilidades**

A cada uno de los 1,905 clientes del conjunto de prueba se le asignó una probabilidad estimada de churn mediante el modelo de regresión logística entrenado. Las probabilidades oscilan entre 0.000002 y 0.2902, con una media de 0.054, lo que refleja que el churn es un evento poco frecuente en la base de clientes de QWE, la mayoría de los clientes tiene una probabilidad baja de abandonar, pero existe un grupo reducido con riesgo notablemente más alto.

2. **Lista de los 100 clientes más riesgosos** — ordenados de mayor a menor probabilidad

| ID | Edad Cliente (meses) | CHI Score | Prob. Churn |
|---|---|---|---|
| 2690 | 27 | 165 | 29% |
| 1971 | 30 | 0 | 26% |
| 14 | 57 | 0 | 21% |
| 3 | 55 | 0 | 20% |
| 1520 | 35 | 0 | 19% |
| 1929 | 28 | 7 | 19% |
| 1459 | 34 | 0 | 19% |
| 128 | 41 | 31 | 18% |
| 2680 | 27 | 2 | 18% |
| 2922 | 24 | 13 | 18% |
| 2240 | 35 | 0 | 18% |
| 1143 | 32 | 0 | 17% |
| 146 | 42 | 0 | 17% |
| 89 | 46 | 4 | 17% |
| 190 | 42 | 0 | 17% |
| 3604 | 9 | 0 | 17% |
| 1616 | 18 | 2 | 17% |
| 2838 | 25 | 0 | 17% |
| 2289 | 34 | 30 | 16% |
| 1392 | 39 | 0 | 16% |
| 10 | 56 | 78 | 16% |
| 106 | 38 | 0 | 16% |
| 64 | 48 | 39 | 16% |
| 1393 | 39 | 3 | 16% |

| | | | |
|---|---|---|---|
| 3671 | 10 | 0 | 16% |
| 1478 | 35 | 0 | 15% |
| 2235 | 35 | 0 | 15% |
| 62 | 48 | 14 | 15% |
| 1287 | 22 | 24 | 15% |
| 2739 | 26 | 31 | 15% |
| 2296 | 33 | 0 | 15% |
| 5314 | 4 | 6 | 15% |
| 1951 | 30 | 0 | 14% |
| 2295 | 28 | 31 | 14% |
| 2787 | 25 | 44 | 14% |
| 1155 | 23 | 41 | 14% |
| 104 | 28 | 0 | 14% |
| 1953 | 28 | 0 | 14% |
| 1387 | 39 | 81 | 14% |
| 1979 | 29 | 24 | 14% |
| 2916 | 25 | 0 | 14% |
| 2252 | 35 | 33 | 13% |
| 911 | 14 | 17 | 13% |
| 1141 | 30 | 3 | 13% |
| 2919 | 23 | 0 | 13% |
| 3569 | 9 | 0 | 13% |
| 1491 | 31 | 28 | 13% |
| 2766 | 17 | 36 | 13% |
| 2334 | 33 | 89 | 13% |
| 63 | 47 | 53 | 13% |
| 1210 | 22 | 0 | 13% |
| 585 | 17 | 10 | 13% |
| 1563 | 18 | 0 | 13% |
| 2157 | 18 | 20 | 13% |
| 1843 | 27 | 12 | 13% |
| 622 | 14 | 0 | 13% |
| 2248 | 35 | 81 | 13% |
| 138 | 41 | 60 | 13% |
| 1303 | 21 | 0 | 13% |
| 86 | 46 | 61 | 13% |
| 3044 | 23 | 42 | 13% |

| | | | |
|---|---|---|---|
| 2156 | 19 | 0 | 12% |
| 1719 | 17 | 100 | 12% |
| 3790 | 9 | 53 | 12% |
| 2602 | 28 | 42 | 12% |
| 1617 | 18 | 0 | 12% |
| 3011 | 24 | 71 | 12% |
| 1188 | 20 | 35 | 12% |
| 1558 | 18 | 15 | 12% |
| 1774 | 17 | 0 | 12% |
| 1538 | 18 | 5 | 12% |
| 228 | 14 | 5 | 12% |
| 2007 | 28 | 34 | 12% |
| 158 | 42 | 33 | 12% |
| 689 | 16 | 0 | 12% |
| 775 | 16 | 0 | 12% |
| 645 | 16 | 0 | 12% |
| 84 | 47 | 35 | 12% |
| 1152 | 16 | 0 | 12% |
| 2277 | 16 | 7 | 12% |
| 4021 | 7 | 57 | 12% |
| 891 | 15 | 0 | 12% |
| 947 | 15 | 0 | 12% |
| 945 | 15 | 0 | 12% |
| 4493 | 17 | 7 | 12% |
| 1910 | 30 | 48 | 12% |
| 994 | 14 | 0 | 12% |
| 868 | 15 | 43 | 12% |
| 991 | 9 | 0 | 12% |
| 48 | 50 | 115 | 12% |
| 3356 | 10 | 0 | 12% |
| 1273 | 21 | 55 | 12% |
| 3428 | 4 | 0 | 12% |
| 47 | 48 | 57 | 12% |
| 2902 | 24 | 30 | 12% |
| 1504 | 36 | 70 | 11% |
| 3997 | 9 | 0 | 11% |
| 416 | 13 | 0 | 11% |

| | | | |
|---|---|---|---|
| 1383 | 38 | 28 | 11% |
| 227 | 13 | 0 | 11% |

3. **Evaluación del modelo**

Con un umbral definido en el percentil 90 de las probabilidades predichas, la matriz de confusión arrojó los siguientes resultados:

| Real | Predicho | Freq |
|---|---|---|
| 0 | 0 | 1655 |
| 1 | 0 | 59 |
| 0 | 1 | 168 |
| 1 | 1 | 23 |

- **Accuracy: 88.1%** el modelo clasifica correctamente al 88.1% de los clientes.
- **Sensibilidad: 28%** de los clientes que realmente hacen churn, el modelo identifica correctamente al 28%. Este valor es bajo, lo que indica que el modelo pierde muchos churns reales.
- **Especificidad: 90.8%** de los clientes que no hacen churn, el modelo los clasifica correctamente el 90.8% de las veces.

| Métrica | Valor |
|---|---|
| Accuracy | 0,8808 |
| Sensibilidad | 0,2805 |
| Especificidad | 0,9078 |

La baja sensibilidad es esperable dado el desbalance de clases: solo el 4.3% de los clientes en el conjunto de prueba hizo churn, lo que hace que el modelo tienda a predecir "no churn" con mayor frecuencia.

**Matriz de confusión:**

| Matriz de confusión | | |
|---|---|---|
| | Predicho: Churn (0) | Predicho: Churn (1) |
| Real: No Churn (0) | 1807 | 0 |
| Real: Churn (1) | 96 | 0 |

| Métricas | |
|---|---|
| Métrica | Valor |
| Accuracy | 94,96% |
| Sensitivity | 0% |
| Specificity | 100% |

La matriz de confusión revela una limitación importante del modelo con umbral 0.5: dado el marcado desbalance de clases (94.9% no churners vs. 5.1% churners), el modelo tiende a clasificar todos los clientes como no churners, obteniendo una accuracy aparente del 94.96% pero una sensibilidad de 0%. Esto significa que no logra identificar correctamente ningún cliente que realmente se va. Esta es una consecuencia esperada del desbalance de clases, y explica por qué la evaluación principal del modelo se apoya en el AUC de la curva ROC, que es independiente del umbral.

4. **Curva ROC y AUC**

La curva ROC (Receiver Operating Characteristic) mide la capacidad del modelo para distinguir entre clientes que harán churn y los que no, a través de todos los umbrales posibles de clasificación. El eje vertical representa la sensibilidad (qué tan bien detecta los churns reales) y el eje horizontal representa 1 menos la especificidad (qué tan bien evita falsas alarmas).

El modelo obtuvo un **AUC de 0.6497**. Para interpretar este número correctamente hay que tener dos referencias claras: un AUC de 0.5 equivale a un modelo completamente aleatorio, sin ningún poder predictivo, sería una línea diagonal recta. Un AUC de 1.0 sería un modelo perfecto. Con 0.6497, el modelo de QWE se ubica por encima de la aleatoriedad, lo que significa que **tiene capacidad real de discriminación**, aunque moderada.

Visualmente la curva se aleja de la diagonal en la parte superior izquierda, especialmente en rangos de baja especificidad, lo que indica que el modelo logra capturar una porción importante de los churns reales antes de generar demasiadas falsas alarmas.

Este AUC es razonable considerando que el modelo usa únicamente 11 variables y datos de solo dos meses. Para mejorar este valor se recomienda incorporar más historia de comportamiento del cliente, variables de interacción entre CHI Score y actividad de login, y explorar modelos más complejos como Random Forest o Gradient Boosting.

| Métrica | Valor |
|---|---|
| AUC | 0,6497 |

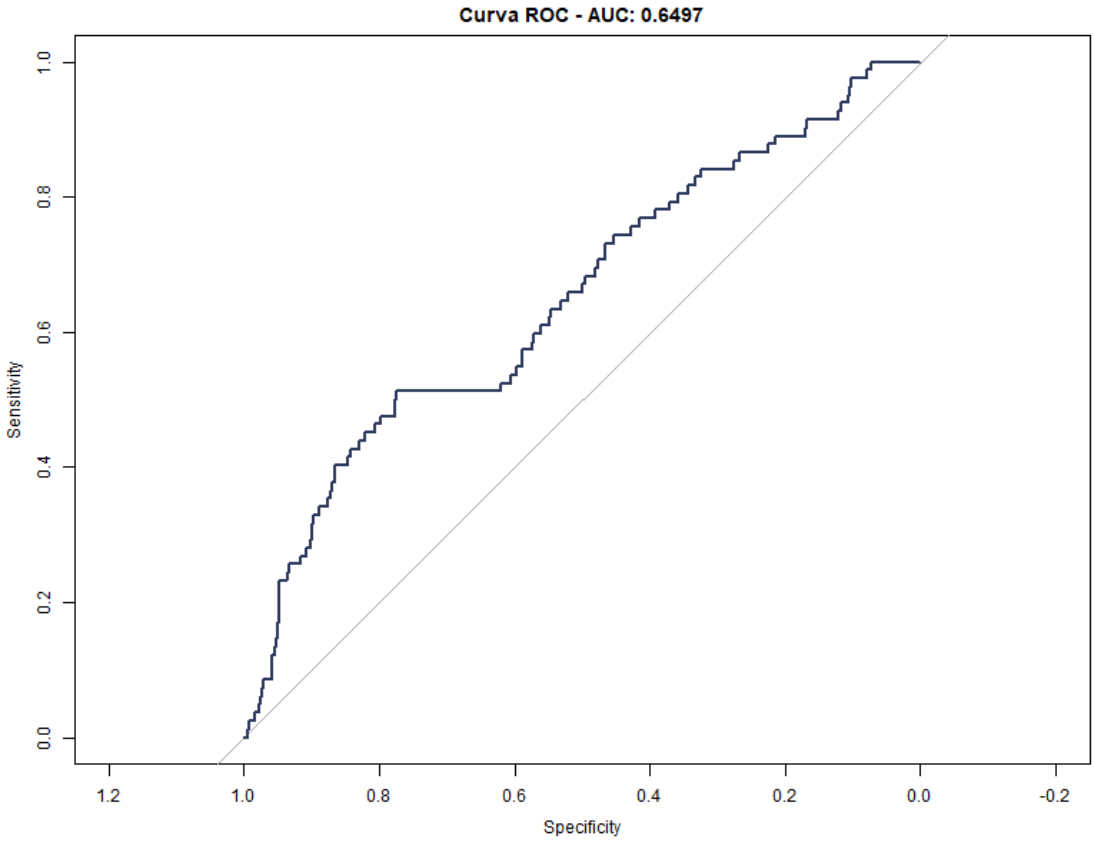

### Gráfico de errores

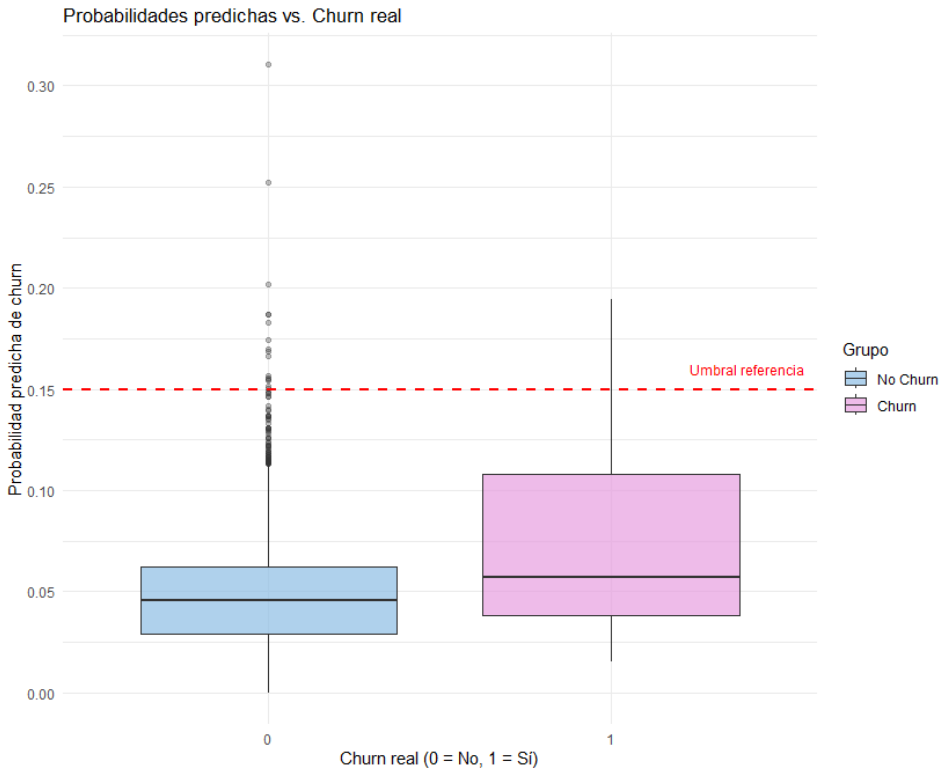


El gráfico de errores muestra la distribución de las probabilidades predichas según el churn real de cada cliente. Los clientes que efectivamente cancelaron (grupo 1) presentan probabilidades predichas más altas y mayor dispersión, con una caja que se extiende hasta 0.11 y valores atípicos cercanos a 0.20. En contraste, los clientes que se quedaron (grupo 0) concentran sus probabilidades alrededor de 0.05 con menor variabilidad. La línea de referencia en 0.15 ilustra que la mayoría de ambos grupos queda por debajo de ese umbral, lo que refleja el desbalance del dataset y explica la baja sensibilidad del modelo. Sin embargo, la diferencia visible entre las cajas confirma que el modelo sí logra asignar probabilidades sistemáticamente más altas a los churners reales.

## 5. Conclusiones y recomendaciones

### Conclusiones

El modelo de regresión logística desarrollado para QWE Inc. demuestra que es posible anticipar el comportamiento de churn de los clientes con base en información disponible en el momento del análisis. Los principales hallazgos son:

El modelo identificó que los factores más determinantes del churn son el **CHI Score actual**, la **caída reciente en el CHI Score** y los **días transcurridos sin iniciar sesión**. Esto confirma la intuición de Richard Wall: la satisfacción del cliente y su nivel de actividad en la plataforma son las señales más tempranas y confiables de que un cliente está considerando abandonar el servicio.

Con un **AUC de 0.6497** y una **accuracy del 88.1%**, el modelo tiene capacidad predictiva real aunque moderada. La sensibilidad del 28% indica que aún se escapan muchos churns reales, lo cual es un área de mejora clara. Sin embargo, incluso con estas limitaciones, el modelo ya permite priorizar esfuerzos de retención de forma mucho más eficiente que el enfoque reactivo que tenía QWE hasta 2012.

La lista de los **100 clientes más riesgosos** representa una herramienta concreta y accionable para el equipo de servicio al cliente, que antes no contaba con ningún criterio objetivo para decidir a quién contactar primero.

**Recomendaciones**

**1. Actuar sobre los 100 clientes identificados de inmediato.** El equipo de Wall debería contactar a estos clientes antes de que decidan cancelar, ofreciendo una experiencia personalizada — no necesariamente descuentos, sino atención proactiva que demuestre que QWE valora su permanencia. Esto es exactamente el cambio de enfoque reactivo a proactivo que Wall buscaba.

**2. Crear un sistema de alertas basado en el CHI Score.** Dado que la caída en el CHI Score es el predictor más fuerte, QWE debería implementar alertas automáticas cuando el score de un cliente cae por encima de un umbral definido en un mes. Eso permitiría intervenir en tiempo real sin necesidad de correr el modelo cada vez.

**3. Monitorear la inactividad de login.** Los clientes que dejan de usar la plataforma son candidatos claros a churn. Una campaña de reenganche dirigida a clientes con más de X días sin conectarse, correos personalizados, tutoriales, recordatorios de valor, podría recuperar parte de ese grupo antes de que lleguen al punto de cancelación.

**4. Mejorar el modelo con más datos.** El AUC de 0.65 deja margen de mejora. Se recomienda incorporar más meses de historia, variables de interacción entre satisfacción y actividad, y evaluar modelos más complejos como Random Forest. Un modelo más robusto elevaría la sensibilidad y permitiría detectar más churns reales con mayor precisión.

**5. Repetir el análisis periódicamente.** El comportamiento de los clientes cambia con el tiempo. El modelo debería reentrenarse cada trimestre con datos actualizados para mantener su poder predictivo y adaptarse a nuevos patrones de comportamiento.

**Las 4D en el Caso**

| **Natalia Valencia Casallas** Puntos 1 y 2 — Exploración y descripción de datos | |
|---|---|
| **D1** | **Delegación** |

***¿Qué preguntas decidiste responder y por qué? ¿Qué le asignaste a la IA? ¿Qué mantuviste bajo tu propio criterio?***

Me encargué de la exploración y descripción de datos (Puntos 1 y 2) por ser la base conceptual del análisis. Leí el caso completo y exploré el Excel de forma independiente para identificar las variables disponibles y el objetivo del problema. Le delegué a la IA apoyo puntual en la escritura de código R, específicamente para la exportación de tablas y la estructura de los gráficos, dado que tengo claridad conceptual pero no domino completamente la sintaxis. Mantuve bajo mi criterio la identificación de variables relevantes según el contexto del negocio, las decisiones estéticas de los gráficos y la redacción final de las interpretaciones.

| **D2** | **Descripción** |
|---|---|

***Copia literal 1-2 prompts que usaste. ¿Funcionó a la primera? ¿Por qué lo ajustaste?***

Prompt 1: «Leí el caso Predicting Customer Churn at QWE Inc. El objetivo es predecir qué clientes tienen mayor probabilidad de cancelar. Ya sé R. ¿Por qué regresión logística es la técnica adecuada y qué variables deberían ser más relevantes según el contexto del caso?»

Prompt 2: «Ya tengo el summary() corriendo. Quiero exportar una tabla de estadísticos descriptivos (mínimo, Q1, mediana, media, Q3, máximo y desviación estándar) en Excel con dplyr y writexl.»

Ambos funcionaron a la primera porque fueron específicos: indiqué qué sabía hacer, qué tenía resuelto y qué necesitaba. En el primero pedí criterio analítico; en el segundo, apoyo técnico acotado.

| **D3** | **Discernimiento** |
|---|---|

***¿Hubo alguna salida que tuviste que corregir o descartar? ¿Cómo supiste que algo estaba mal?***

Sí, hubo dos situaciones concretas. Primera: el gráfico de distribución de churn tenía pocas marcas en el eje Y, dificultando la lectura. Lo identifiqué visualmente y pedí agregar scale_y_continuous con intervalos de 500. Segunda: el boxplot de días desde último login tenía un outlier de -650 que aplastaba toda la visualización. Lo detecté visualmente y pedí

limitar el eje Y con coord_cartesian sin eliminar datos del cálculo. En ambos casos el juicio de que algo estaba mal fue mío; la IA solo ejecutó la corrección.

| D4 | Diligencia |
|---|---|

***¿Cuál es el resultado del que estás más segura? ¿Y el que más dudas te genera? ¿Podrías defender tu análisis sin el script?***

El resultado del que estoy más segura es la tabla de medias por grupo: el CHI Score promedio de 63.27 en churners versus 88.61 en no churners es una diferencia concreta que puedo explicar y defender. El que más dudas me genera es el boxplot de casos de soporte, donde ambas cajas quedan en cero y no es claro si la variable no aporta o si es un problema de escala. Podría defender todo el análisis descriptivo sin el script: entiendo qué variables se compararon, qué mostraron los gráficos y qué significan las diferencias. La IA participó en la escritura del código y la estructura inicial de interpretaciones; las decisiones analíticas y la redacción final fueron mías.

| **Juan Pablo Mora Benavides** Punto 3 — Modelo de regresión logística | |
|---|---|
| **D1** | **Delegación** |

***¿Qué preguntas decidiste responder y por qué? ¿Qué le asignaste a la IA? ¿Qué mantuviste bajo tu propio criterio?***

Me encargué de la construcción e interpretación del modelo de regresión logística. Las decisiones analíticas —qué variables incluir, cómo interpretar los coeficientes y qué conclusiones extraer para QWE— las tomé yo. Le delegué a la IA la construcción del código optimizado para generar las tablas de coeficientes, odds ratios e intervalos de confianza, así como el diseño visual de los resultados. El criterio sobre qué variables son relevantes para el negocio y la redacción de la interpretación fueron míos.

| D2 | Descripción |
|---|---|

***Copia literal 1-2 prompts que usaste. ¿Funcionó a la primera? ¿Por qué lo ajustaste?***

El prompt principal fue: «Eres un analista experto en programación. Revisa este caso y desarrolla el código que resuelva la Parte 3. Usa el archivo .R para guiarte en los nombres de variables y continúa sobre ese código. En el Excel está la data.» Los resultados iniciales tuvieron que verificarse para confirmar consistencia con la base de datos. Se hicieron ajustes al prompt para que las tablas y gráficos tuvieran mayor nivel de detalle, aunque no fue

necesario agregar información adicional ya que se proporcionaron todos los archivos desde el inicio.

| D3 | Discernimiento |
|---|---|

***¿Hubo alguna salida que tuviste que corregir o descartar? ¿Cómo supiste que algo estaba mal?***

Se verificó que el código no repitiera procesos lógicos ni tuviera funciones en conflicto — por ejemplo, renombramiento de variables duplicado o rutas de exportación inconsistentes. Con el apoyo de VSCode se detectaron errores menores de sintaxis y se reemplazaron librerías que no funcionaban correctamente por alternativas más compatibles con el proyecto.

| D4 | Diligencia |
|---|---|

***¿Cuál es el resultado del que estás más seguro? ¿Y el que más dudas te genera? ¿Podrías defender tu análisis sin el script?***

Los resultados de mayor confianza son los coeficientes estadísticamente significativos: CHI Score M0, CHI Score 0-1 y Days Since Last Login, que tienen p-valores menores a 0.01 y odds ratios interpretables en términos de negocio. Las variables con p-valores altos generan dudas sobre su aporte real al modelo. Con preparación previa puedo defender el análisis explicando qué representa cada coeficiente, por qué se usan odds ratios y cómo se identifican los tres factores principales de churn. La IA participó en la generación de código optimizado; el análisis e interpretación de resultados fueron míos.

| **Daniela Ramírez Castaño** Punto 4 — Evaluación y aplicación del modelo | |
|---|---|
| **D1** | **Delegación** |

***¿Qué preguntas decidiste responder y por qué? ¿Qué le asignaste a la IA? ¿Qué mantuviste bajo tu propio criterio?***

Me encargué de la evaluación del modelo: ¿qué tan bien predice?, ¿a quiénes identifica como más riesgosos? y ¿cómo se mide su capacidad discriminatoria? Le delegué a la IA la construcción del código para la matriz de confusión, el cálculo de métricas, la curva ROC y la exportación a Excel, dando pautas específicas sobre el formato esperado. Mantuve bajo mi criterio la interpretación de qué significan esos números en el contexto real de QWE y qué decisiones de negocio se derivan de ellos.

| D2 | Descripción |
|---|---|

***Copia literal 1-2 prompts que usaste. ¿Funcionó a la primera? ¿Por qué lo ajustaste?***

El prompt principal fue: «Punto 4: predicción de probabilidades, lista de los 100 clientes más riesgosos, matriz de confusión, accuracy, sensibilidad, curva ROC y AUC. Expórtalo todo a Excel.» No funcionó a la primera: el umbral inicial de 0.5 hacía que el modelo clasificara a todos los clientes como no churn, generando una matriz con una sola columna activa. Revisé la distribución de las probabilidades predichas y ajusté el umbral al percentil 90 para que el modelo identificara un grupo de riesgo real.

| D3 | Discernimiento |
|---|---|

***¿Hubo alguna salida que tuviste que corregir o descartar? ¿Cómo supiste que algo estaba mal?***

La salida que tuve que corregir fue la matriz de confusión. Supe que estaba mal porque al imprimirla solo aparecía una columna —todos los clientes predichos como 0— lo que hace inútiles las métricas de evaluación. También descarté la primera versión de exportación a Excel porque la ruta generaba un error de archivo inválido, lo que verifiqué abriendo la carpeta de destino y confirmando que el archivo no había sido creado.

| D4 | Diligencia |
|---|---|

***¿Cuál es el resultado del que estás más segura? ¿Y el que más dudas te genera? ¿Podrías defender tu análisis sin el script?***

El resultado del que estoy más segura es el AUC de 0.6497: la curva ROC se aleja claramente de la diagonal, confirmando que el modelo tiene poder predictivo real más allá del azar. El resultado que más dudas me genera es la sensibilidad del 28%, que significa que de cada 10 clientes que van a hacer churn, el modelo solo detecta correctamente a 3 (una limitación importante para el objetivo de QWE). Podría defender el análisis sin el script explicando qué representa cada métrica y por qué el umbral del percentil 90 tiene sentido dado el desbalance de clases. La IA participó en la escritura y corrección del código; las decisiones sobre qué corregir, cómo interpretar y qué concluir fueron mías.